

Organização e Arquitetura de Computadores

Desempenho

Prof. Msc. Lucas Reis

lucas.oliveira@puc-campinas.edu.br

+ Design para Desempenho

- O custo de sistemas computacionais cai dramaticamente, e seu desempenho também aumenta drasticamente
- Processadores são tão baratos, que hoje são descartáveis
- Empresas se orientam na arquitetura servidor-cliente para atender uma vasta maioria das necessidades computacionais modernas
- Provedores de nuvem usam bancos de servidores de alto desempenho para satisfazer o altíssimo volume de requisições em diversos espectros de aplicações e clientes



+ Velocidade do Microprocessador


Técnicas aplicadas em microprocessadores modernos incluem:




Pipelining	•Movimentação de dados e instruções em “pipes”
Predição de desvios	•Processador prevê instruções à frente baseado em uma suposição da decisão de salto de um programa
Execução superescalar	•Capacidade de despachar mais de uma instrução por ciclo
Análise de dataflow	•Avaliar quais instruções dependem de quais para criar um fluxo ótimo de execução sem dependências
Execução especulativa	•Usando predição de desvios e análise de dataflow, processadores executam instruções de maneira especulativa, antes mesmo de elas ocorrerem no fluxo atual de execução do programa. Assim, mantém as unidades de execução o mais ocupadas possível



Melhorias na Arquitetura e Organização de chips




- Aumento da velocidade do chip
 - Consequência da redução do tamanho das portas lógicas
 - Mais portas, mais densamente alocadas => aumento na velocidade do clock
 - Tempo de propagação para sinal reduzido
- Aumento do tamanho e velocidade das caches
 - Roubando parte do chip para cache => Tempo de acesso reduzido
- Mudança da organização e arquitetura do processador
 - Aumento na velocidade efetiva da execução de uma instrução
 - Paralelismo





Limitantes da velocidade de clock de um chip



- Potência
 - Densidade de potência aumenta com aumento da densidade do chip e velocidade de clock
 - Maior dissipação de calor
- Delay RC
 - Velocidade com que elétrons fluem é limitada pela resistência e capacitância dos caminhos no chip
 - Redução de tamanho nos componentes do chip causam redução do tamanho das conexões, aumentando a resistência
 - Redução da distância das conexões também aumenta capacitância
- Latência da memória
 - Velocidade da memória está sempre abaixo da velocidade do processador






Figure 2.2 Processor Trends

Multicore





Lei de Amdahl



- Gene Amdahl
- Lida com potencial de *speedup* de um programa usando múltiplos processadores, em oposição a apenas um
- Ilustra os problemas que a indústria lida para o desenvolvimento de arquiteturas multi-core
 - Software deve ser adaptado para um ambiente de execução paralelo, assim aproveitando a arquitetura multicore
- Pode ser generalizada para avaliar ganhos de desempenho em software




Figure 2.3 Illustration of Amdahl's Law








Figure 2.4 Amdahl's Law for Multiprocessors


O que é Desempenho?

- Qual avião tem o melhor desempenho?



Latência e Throughput

- Latência
 - Quanto tempo leva para fazer uma tarefa
- Throughput
 - Quantidade de trabalho por unidade de tempo
 - por exemplo, tarefas por hora, transações por minuto...



* Slides gentilmente fornecidos pelo prof. Isaías Felzmann

Latência e Throughput

- Latência
 - Quanto tempo leva para fazer uma tarefa
- Throughput
 - Quantidade de trabalho por unidade de tempo
 - por exemplo, tarefas por hora, transações por minuto...
- Como latência e throughput são afetados por
 - Trocar o processador por um mais rápido?
 - Adicionar mais processadores?
- Vamos focar na latência, por enquanto...

Desempenho relativo

- Desempenho = $1/\text{Tempo de execução}$
- “X é n vezes mais rápido que Y”

$$\frac{\text{Desempenho}_X}{\text{Desempenho}_Y} = \frac{\text{Tempo}_Y}{\text{Tempo}_X} = n$$

Desempenho relativo

- Desempenho = $1/\text{Tempo de execução}$
- “X é n vezes mais rápido que Y”

$$\frac{\text{Desempenho}_X}{\text{Desempenho}_Y} = \frac{\text{Tempo}_Y}{\text{Tempo}_X} = n$$

- Exemplo: Tempo para executar um programa P
 - 10 s em A, 15s em B
 - $\text{Tempo}_B / \text{Tempo}_A$
 $= 15 \text{ s} / 10\text{s} = 1,5$
 - Então A é 1,5 vezes mais rápido que B $\rightarrow$
1,5 X


Medindo tempo de execução

- Tempo real (relógio)
 - Tempo de resposta total, incluindo todos os aspectos
 - Processamento, E/S, tempo de espera...
 - Determina o desempenho do Sistema
- Tempo de CPU
 - Tempo gasto no processamento
 - Desconta E/S e outras tarefas paralelas
 - Dividido em tempo de usuário e tempo do sistema
 - Programas diferentes são afetados de forma diferente

* Slides gentilmente fornecidos pelo prof. Isaías Felzmann

Clock da CPU

- Taxa de atualização dos elementos de hardware na CPU



- Período de clock: duração de um ciclo
 - $250 \text{ ps} = 0.25 \text{ ns} = 250 \times 10^{-12} \text{ s}$
- Frequência de clock: ciclos por segundo
 - $4.0 \text{ GHz} = 4000 \text{ MHz} = 4.0 \times 10^9 \text{ Hz}$

		ann
femto	f	10^{-15}
pico	p	10^{-12}
nano	n	10^{-9}
micro	μ	10^{-6}
mili	m	10^{-3}
--	-	10^0
kilo	k	10^3
mega	M	10^6
giga	G	10^9
tera	T	10^{12}
peta	P	10^{15}
exa	E	10^{18}

Tempo de CPU

$$\text{Tempo CPU} = \# \text{ ciclos} \times \text{período clock} = \frac{\# \text{ ciclos}}{\text{frequência clock}}$$

- Desempenho melhorado por
 - Reduzir o número de ciclos
 - Aumentar frequência do clock
- Geralmente, as duas coisas vão em sentido contrário

Exemplo de tempo de CPU

- Computador A: Clock 2 GHz, 10 s tempo de CPU
- Projetando um computador B
 - Queremos 6 s de tempo de CPU
 - Um clock mais rápido aumenta 20% o número de ciclos
- Quanto deve ser o clock do computador B?

$$\text{tempo}_B = \frac{\text{ciclos}_B}{\text{frequência}_B} \rightarrow \text{frequência}_B = \frac{1,2 \times \text{ciclos}_A}{6 \text{ s}}$$

$$\text{tempo}_A = \frac{\text{ciclos}_A}{\text{frequência}_A} \rightarrow \text{ciclos}_A = 10 \text{ s} \times 2 \text{ GHz} = 20 \times 10^9$$

$$\text{frequência}_B = \frac{1,2 \times 20 \times 10^9}{6 \text{ s}} = \frac{24 \times 10^9}{6 \text{ s}} = 4 \text{ GHz}$$

Contagem de instruções e CPI

ciclos = # instruções × Ciclos por Instrução

$$\text{Tempo CPU} = \# \text{instruções} \times \text{CPI} \times \text{período clock} = \frac{\# \text{instruções} \times \text{CPI}}{\text{frequência clock}}$$

- # Instruções: Contagem de instruções em um programa
 - Determinado pelo programa, ISA, compilador...
- CPI: Ciclos por Instrução (na média)
 - Determinado pelo Hardware da CPU
 - Se instruções diferentes tem CPI diferente
 - Média depende da composição de instruções

* Slides gentilmente fornecidos pelo prof. Isaías Felzmann

Exemplo com CPI

- Computador A: Período = 250 ps, CPI = 2,0
- Computador B: Período = 500 ps, CPI = 1,2
- Mesmo ISA
- Qual é mais rápido e quanto?

$$\begin{aligned}\text{tempo}_A &= \text{instruções} \times \text{CPI}_A \times \text{período}_A = \\ &= 1 \times 2,0 \times 250 \text{ ps} = 1 \times 500 \text{ ps}\end{aligned}$$

A é mais rápido

$$\begin{aligned}\text{tempo}_B &= \text{instruções} \times \text{CPI}_B \times \text{período}_B = \\ &= 1 \times 1,2 \times 500 \text{ ps} = 1 \times 600 \text{ ps}\end{aligned}$$

$$\frac{\text{tempo}_B}{\text{tempo}_A} = \frac{1 \times 600 \text{ ps}}{1 \times 500 \text{ ps}} = 1,2$$

em 1,2 X (ou 20%)

CPI médio

- Se instruções de n classes diferentes têm latências (em ciclos) diferentes

$$\# \text{ ciclos} = \sum_i (\text{CPI}_i \times \# \text{ instruções}_i)$$

- CPI Médio

$$\text{CPI} = \frac{\# \text{ ciclos}}{\# \text{ instruções}} = \sum_i \left(\text{CPI}_i \times \frac{\# \text{ instruções}_i}{\# \text{ instruções}} \right)$$

Exemplo com CPI e classes diferentes

- Programas 1 e 2 compilados com classes de instruções A, B e C

Classe	A	B	C
CPI da classe	1	2	3
#instruções no programa 1	2	1	2
#instruções no programa 2	4	1	1

- Programa 1: IC = 5
 - Ciclos
 $= 2 \times 1 + 1 \times 2 + 2 \times 3$
 $= 10$
 - CPI médio = $10/5 = 2.0$
- Programa 2: IC = 6
 - Ciclos
 $= 4 \times 1 + 1 \times 2 + 1 \times 3$
 $= 9$
 - CPI médio = $9/6 = 1.5$

Exemplo com CPI e classes diferentes

- Programas 1 e 2 compilados com classes de instruções A, B e C

Classe	A	B	C
CPI da classe	1	2	3
#instruções no programa 1	2	1	2
#instruções no programa 2	4	1	1

- Programa 1: IC = 5
 - Ciclos
 $= 2 \times 1 + 1 \times 2 + 2 \times 3$
 $= 10$
 - CPI médio $= 10/5 = 2.0$
- Programa 2: IC = 6
 - Ciclos
 $= 4 \times 1 + 1 \times 2 + 1 \times 3$
 $= 9$
 - CPI médio $= 9/6 = 1.5$

Quem é mais rápido?